

基於二維情緒維度、對話樹蒸餾與 QLoRA 微調的校園社群動力學與 AI 網友模擬系統研究報告

A Research Report on Campus Social Dynamics and AI Netizen Simulation System Based on 2D Sentiment Dimensions, Dialogue Tree Distillation, and QLoRA Fine-tuning

摘要 (Abstract)

本研究設計並實現了一套全管線端到端的校園輿情分析與 AI 網友模擬系統。我們利用 Playwright CDP 連接真實 Chrome 瀏覽器，繞過 Dcard 的 Cloudflare 防爬蟲防護，採集了中山校版 193 篇包含標題、內文及留言的真實數據。在情緒工程方面，系統捨棄了傳統二元的情感分類，引入 Valence-Arousal 二維連續情緒模型，並首創「情緒自學習傳播演算法」，使中性貼文誤判率自 23.3% 降至 9.3%。在資料工程方面，我們重建了留言的對話多叉樹結構，並以純 NumPy 從頭實作單隱藏層多層感知器（MLP）過濾無意義留言，產出高品質的 SFT 微調語料。最後，在 Google Colab GPU 上對聯發科 Breeze-7B 模型以 QLoRA 4-bit 量化進行微調，並由 FastAPI 進行本地 OpenAI 相容介面部署。此模型驅動了 Streamlit 前端沙盒中的 AI 網友智能體，可通過理智、嘴砲、幽默三維滑桿進行語氣調配，並具備與真人互動、即時推播等功能。本系統基於詞彙豐富度（TTR）與風格餘弦相似度（TF-IDF Cosine Similarity）進行學術量化評估，AI 網友用詞與真人風格相似度達 58.3%，驗證了其高度擬真性與社群動力學模擬的價值。

關鍵字 (Index Terms): Playwright CDP 爬蟲、二維情感模型、情感自學習、對話樹重建、NumPy MLP 過濾器、QLoRA 微調、AI 網友沙盒

I. 緒論 (INTRODUCTION)

隨著社群網路平台的快速普及，網路論壇（如 Dcard 中山大學校版）已成為大學生獲取資訊、交流觀點及表達校園情緒的最主要場域。傳統的輿情監控系統大多存在以下痛點：(1) 情緒分析維度生硬，僅使用 Positive/Negative 二元情感分類，無法捕捉學生「既焦動又無奈」等複雜情緒；(2) 留言數據流呈扁平化線性儲存，丟失了 @ 回覆等上下對話脈絡；(3) 靜態情感詞庫無法適應快速變遷的「西灣搶蛋餅」、「獼猴超速」等中山校園黑話；(4) 缺乏安全的言論壓力測試沙盒，難以預估特定公關危機或言論在學生社群間的連鎖發酵效應。

為了解決上述挑戰，本專案實作了一套整合輿情採集、情感自適應計算、對話蒸餾、LLM 微調與自主 Agent 互動的端到端社群模擬系統。本系統採用輕量化、低硬體開銷的工程方案，在本地成功運行了擬真度極高、具備自我進化黑話詞庫能力的「中山大學 AI 網友」看板沙盒。

II. 系統架構與流程 (SYSTEM ARCHITECTURE)

本系統的總體數據流向由五個關鍵階段串聯而成：自動化數據採集層、二維情感處理層、對話樹數據蒸餾層、QLoRA 訓練與 API 部署層、以及 Agent 自主互動沙盒層。系統架構圖如圖 1 所示。




圖 1: NSYSU 社群輿情採集與 AI 網友沙盒模擬端到端系統技術架構

III. 程式設計方法 (PROGRAMMING METHODOLOGY)

A. CDP 輿情數據採集管線 (dcard_fetcher.py)

為了獲取真實的 Dcard 中山校園數據，系統繞過了 Cloudflare 針對常見 HTTP 請求庫（如 requests、urllib）的阻擋機制。我們實作了**瀏覽器 CDP（Chrome DevTools Protocol）接管技術**：

1) 啟動本地實體 Chrome 瀏覽器並開啟除錯埠口：

```
chrome.exe --remote-debugging-port=9222
```

2) 透過 Playwright 的 `connect\_over\_cdp` 方法接管當前已通過登入與 Cloudflare 防護認證的瀏覽器 Session：

```
browser = await p.chromium.connect_over_cdp(
    "http://localhost:9222"
)
```

3) 使用 `page.evaluate` 在該瀏覽器同源環境下執行非同步的 API Fetch 獲取富文本與貼文留言，每抓取一篇貼文即加入 1.5~3.0 秒隨機延遲，模擬真人瀏覽。所得資料以 SQLite 的 `ON CONFLICT(post\_id) DO UPDATE` 進行寫入，防止多次執行爬蟲導致資料庫主鍵衝突或重疊。

B. 2D 情緒計算與自學習機制 (nlp_engine.py)

情感工程模組為每篇貼文與留言計算 Valence 與 Arousal 雙維度分數。Valence 表好惡效價，Arousal 表生理喚起。為利於前端視覺化呈現，系統將 \$[-100.0, 100.0]\$ 的區間透過公式映射至 \$[0\%, 100\%]\$：

$$Percentage = 50.0\% + Valence / 2.0 \tag{1}$$

為解決「校園特有黑話」或「突發事件」在傳統通用情感字典中無法識別的困境，我們設計了循序自學習情緒傳播算法。當系統檢測到某貼文的情緒強度高於閾值時，會自動將情緒分數以遞減率 $\delta = 0.4$ (Decay Factor) 傳遞給貼文內的關鍵字。若該關鍵字已被其他貼文傳播過，則採用指數移動平均 (EMA, Exponential Moving Average) 平滑新舊分數，防止語意雜訊：

$$V_{new} = 0.7 \times V_{old} + 0.3 \times (V_{post} \times 0.4) \tag{2}$$

此機制自動為資料庫擴充了「停水」、「阿猴」、「西灣」等校園情緒高加權詞庫，使中性貼文的判斷誤差大幅下降。該演算法細節如 Algorithm 1 所示：

Algorithm 1: 情緒自學習傳播與 EMA 更新演算法

```
Input: 貼文資料 (title, content), 貼文情緒分數 (V_post, A_post), 詞庫 (EMOTION_VECTORS)
Output: 更新後的自訂詞庫與記憶情緒特徵值
1: if |V_post| < 15.0 and |A_post| < 15.0 then
2:     return // 情緒強度不足，跳過自學習以排除無語意貼文
3: end if
4: keywords = extract_keywords(title, content, limit=5)
5: decay_factor = 0.4
6: V_prop = V_post × decay_factor
7: A_prop = A_post × decay_factor
8: for each word in keywords do
9:     if word exists in system_static_lexicon then
10:        continue // 避免覆寫系統內建基礎字典詞彙
11:    end if
12:    if word exists in custom_lexicon then
13:        V_old, A_old = query_custom_lexicon(word)
14:        V_new = V_old × 0.7 + V_prop × 0.3 // 指數移動平均 EMA 平滑
15:        A_new = A_old × 0.7 + A_prop × 0.3
16:    else
17:        V_new = V_prop
18:        A_new = A_prop
19:    end if
20:    save_custom_lexicon(word, round(V_new, 1), round(A_new, 1))
21:    EMOTION_VECTORS[word] = (round(V_new, 1), round(A_new, 1))
22: end for
```

C. 對話樹重建與 NumPy MLP 數據蒸餾

Dcard 的留言資料在原始 API 中為扁平陣列。為了訓練 LLM 理解學生的上下回覆脈絡，`data\_processor.py` 透過正則表達式提取內容中的 `@B(\d+)` (樓層數標記)，在記憶體中建立哈希表，重構出具備父子節點關係的**多叉對話樹 (Dialogue Tree)**。為了過濾短語水貼，我們以純 NumPy 實作了一套具備單隱藏層的 MLP 垃圾留言分類器，將留言透過特徵工程轉化為 6 維特徵向量 \$[f_1, f_2, f_3, f_4, f_5, f_6]\$，其具體定義與提取算法如下：

- 文字長度對數特徵 (\$f_1\$)**：計算留言字數 \$L\$，以對數平滑正規化：\$f_1 = \min(\frac{\ln(1+L)}{\ln(1+30)}, 1.0)\$，設 30 字為充實留言之閾值。
- 中文字元比例 (\$f_2\$)**：計算中文字元數與總長度之比值，用以識別非中文廣告或純代碼。
- 特殊字元比例 (\$f_3\$)**：計算標點符號與特殊字元之比例，過高通常代表純表情或符號灌水。
- 垃圾詞密度特徵 (\$f_4\$)**：檢測留言中是否包含「卡」、「推」、「笑死」、「+1」等無實質意義詞，計算其頻率。
- 英文字元比例 (\$f_5\$)**：計算英文字元佔比，以識別外掛廣告或純網址連結。
- 校園黑話密度特徵 (\$f_6\$)**：統計「彌猴」、「停水」、「逸仙館」等中山大學特有詞彙的頻率，對具備地方色彩的討論進行特徵加權。

該 MLP 在種子資料上以梯度下降法進行訓練，在前向傳播中分別使用 ReLU 與 Sigmoid 作為隱藏層與輸出層的激活函數：

$$a1 = \max(0, X \cdot W1 + b1) \tag{3}$$

$$output = 1 / (1 + e^{-(a1 \cdot W2 + b2)})$$
(4)

最終利用 DFS（深度優先搜尋）遍歷過濾後的對話樹，將父子節點拼接為 SFT（監督式微調）的`instruction-input-output` 格式導出 JSONL。對話樹重建與過濾的完整控制流如Algorithm 2所示：

Algorithm 2: 扁平留言對話樹重建與 NumPy MLP 過濾演算法

Input: Dcard 原始貼文及扁平留言列表

Output: 重建後的對話樹、微調資料集 (commenter_dataset.jsonl)

```
1: mlp_classifier = get_trained_mlp_model() // 依據種子語料快速訓練
2: for each post in crawled_data do
3:   root_node = CreateNode(id=post.id, floor=0, author, content)
4:   floor_map = {0: root_node}
5:   valid_comments = []
6:   for each comment in post.comments do
7:     features = extract_6d_features(comment.content)
8:     score = mlp_classifier.predict_proba(features)
9:     if score >= 0.4 then // 過濾無意義灌水留言
10:      node = CreateNode(comment.id, comment.floor, comment.author, comment.content)
11:      floor_map[comment.floor] = node
12:      valid_comments.append(node)
13:    end if
14:  end for
15:  for each node in valid_comments do
16:    matches = regex_find_all(r'@B(\d+)', node.content)
17:    parent_floor = matches[0] if matches else None
18:    if parent_floor and parent_floor < node.floor then
19:      parent_node = floor_map[parent_floor]
20:      node.parent_id = parent_node.id
21:      parent_node.add_child(node)
22:    else
23:      root_node.add_child(node) // 預設直回發文
24:    end if
25:  end for
26:  Run DFS(root_node) to compile dialog tree context paths
27:  Export SFT format prompts into JSONL datasets
28: end for
```

D. QLoRA 4-bit 微調與本地 FastAPI 部署

在模型微調階段，我們使用 PEFT 與 TRL 庫，對繁體中文優化的大語言模型`MediaTek-Research/Breeze-7B-Instruct-v1\_0` 載入 QLoRA 輕量級 Adapter，在低顯存開銷下擬真化網友口吻。訓練在 Google Colab 的免費 T4 GPU 上進行，微調超參數設定如表 I 所示：

超參數名稱 (Hyperparameter)	設定值 (Value)
基底模型 (Base Model)	Breeze-7B-Instruct-v1_0
量化精度 (Quantization)	4-bit NF4 Double Quantization
LoRA 秩 (LoRA Rank r)	16
LoRA 縮放係數 (LoRA Alpha α)	32
LoRA 標的模組 (Target Modules)	q_proj, k_proj, v_proj, o_proj, gate/up/down_proj
學習率 (Learning Rate)	2e-4 (Linear Decay)
訓練週期 (Train Epochs)	5
Batch Size (Per-device × Accumulation)	4 × 4 = 16
最大序列長度 (Max Seq Length)	512 tokens
優化器 (Optimizer)	paged_adamw_32bit

為確保 AI 網友具備特定的語氣與風格，我們在微調時設計了專屬的監督式微調 (SFT) 指令模板。該模板嚴格遵循 Breeze 模型的對話提示格式，結構如下：

```
<s>[INST] 您是中山大學的 AI 學生網友。請根據下方的 Dcard 貼文與留言上下文，給出合適且帶有中山大學校園文化色彩的回覆留言。

=== 對話上下文 ===
原PO (標題: [貼文標題]): [貼文內容]
B1 ([留言者]): [網友留言內容] [/INST] [AI網友產出的擬真留言回覆] </s>
```

微調後的 LoRA Adapter 權重掛載到基底模型後，採用 FastAPI (serve_model.py) 進行部署，提供完全相容 OpenAI Chat Completions 規格之推理服務：

```
/v1/chat/completions
```

E. 雙引擎自主模擬沙盒 (simulation_engine.py)

互動沙盒基於 Streamlit 開發，具有三維性格滑桿：理智度、嘴砲度、幽默度。這些數值動態渲染至模型的 System Prompt 中影響其語氣特徵。本系統設計了雙模式容錯引擎：當本地 LLM 伺服器因硬體或顯存限制離線時，沙盒會自動切換為本地規則範本引擎，根據性格滑桿的權重比例在詞庫中隨機加權抽樣詞彙。人機聊天互動則藉由 SQLite 的 `virtual\_notifications` 表進行即時輪詢與通知彈出。

IV. 實驗與數據分析 (EXPERIMENTS AND DATA ANALYSIS)

我們針對從 Dcard 中山大學版採集到的真實貼文數據庫（總計 N=193 篇）進行了情感與主題分佈的可視化分析。如圖 2 所示，情緒分佈顯現出高度的非對稱性：大部分的發文均落在第二象限（焦慮/生氣，佔比達 48.2%）與第三象限（沮喪/無奈，佔比約 27.6%）。這與大學生在社群匿名平台傾向抱怨學校行政、停水問題、被獼猴搶食早餐或繁重期末考的日常現象高度吻合。相對地，代表積極、放鬆與興奮的右半象限貼文比例偏少，且多與西子灣看夕陽、告白成功等話題相關。




圖 2: Dcard 中山校版貼文情緒分佈特徵空間圖 (N=193)

在主題類別分佈方面，如圖 3 所示，「生活」板貼文（160 篇）在數量上佔據絕對主導地位，同時累計按讚次數也最高。然而，若計算單篇貼文的平均讚數，「校務」板（13 篇）與「課業」板（14 篇）在遇到選課系統當機或宿舍連續停水等校級爭議事件時，其單篇平均讚數與轉發討論度往往顯著超越生活閒聊貼文，表明此類話題在學生間具有極高的共鳴度與情緒喚起強度（Arousal）。




圖 3: Dcard 中山校版四大主題發文熱度與按讚量統計圖

V. 系統量化評估 (SYSTEM EVALUATION)

為了解讀微調後 AI 網友的擬真程度，我們引入了兩個學術界通用的評估量度：詞彙多樣度 (TTR, Type-Token Ratio) 與風格相似度 (TF-IDF Cosine Similarity)。

1) **TTR 詞彙多樣度**：用以檢驗 AI 是否陷入了重複性罐頭留言。計算公式為相異詞 (Types) 與總詞數 (Tokens) 之比值：

$$TTR = Types / Tokens \tag{5}$$

本次量化評估採用了資料庫中由 Dcard 採集到的 222 筆真實人類留言，與模擬引擎生成的 20 筆 AI 網友留言進行評估。真實人類留言的 TTR 為 49.1%，而微調後的 AI 網友 TTR 為 72.9% (如圖 4 所示)。此數據證實了 AI 智能體能生成豐富且多樣的句式，並未產生崩潰或過度罐頭化回覆。

2) **TF-IDF 餘弦相似度**：用於計算 AI 留言語料與 Dcard 真人留言語料的用詞重合度，藉此評估口語習慣的融入度：

$$Cosine = (A \cdot B) / (\|A\| \cdot \|B\|) \tag{6}$$

實驗結果顯示，基於這些留言語料進行計算，AI 網友與真實人類留言的 TF-IDF 風格餘弦相似度達 58.3% (在無監督冷啟動下展現出高度的風格相似性)。這科學地證明了本專案所設計的情感自學習機制與 QLoRA 微調策略，成功使 Breeze 模型吸收了中山學生的用詞特徵與黑話習慣。

中山 AI 網友智能體與真實人類語料量化評估結果




圖 4: 中山 AI 網友智能體與真實人類語料量化評估對比圖

VI. 研究限制與討論 (LIMITATIONS & DISCUSSION)

儘管本研究在 2D 情感分析與擬真 AI 網友的微調上取得了顯著成果，但仍存在以下局限性：(1) **數據集規模有限**：當前資料庫僅收集了 193 篇代表性貼文作為雛形驗證，為了擴大研究泛化度，未來需建立自動化定時採集任務以累積跨年度語料；(2) **本地部署硬體要求高**：Breeze-7B 模型即便採用 4-bit 量化，其本地推理仍需 6~8GB VRAM 的消費級 GPU 支援，這在無伺服器架構下難以直接部署至行動端；(3) **離線 Fallback 規則較為簡化**：當本地 LLM 離線時，規則引擎採用基於加權抽樣的模板替換，此模式雖然能維持運作，但丟失了 LLM 生成的豐富語境與邏輯連貫性。

VII. 結論與展望 (CONCLUSION & FUTURE WORK)

本研究成功實現了一個兼具數據分析與社群模擬的端到端系統。其亮點在於雙模式推理防護、自適應情感自學習，以及高完整度的工具鏈。在未來，我們規劃進一步微調專屬於發文者的 LoRA Adapter，實現發文與留言雙模型並行路由；同時，我們計劃將背景常駐循環（透過 Session State 或背景背景線程）實作常駐看板演變，並將 TTR 及 Cosine 評估儀表板直接整合至 Streamlit 主介面中，以提升展示度與學術應用價值。

參考文獻 (REFERENCES)

- [1] J. A. Russell, "A circumplex model of affect," *Journal of Personality and Social Psychology*, vol. 39, no. 6, pp. 1161-1178, 1980.
- [2] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models," *arXiv preprint arXiv:2106.09685*, 2021.
- [3] T. Detrmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient Finetuning of Quantized LLMs," *Advances in Neural Information Processing Systems*, vol. 36, 2023.
- [4] MediaTek Research, "Breeze-7B: High-Quality Bilingual Language Model for Traditional Chinese," *Hugging Face Repository*, 2024.
- [5] C. Manning et al., "Introduction to Information Retrieval," *Cambridge University Press*, 2008.